



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное
учреждение высшего образования
«Московский государственный технический университет имени
Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ «Информатика и системы управления»

КАФЕДРА «Программное обеспечение ЭВМ и информационные технологии»

Отчет по лабораторной работе №7 по курсу "Анализ алгоритмов"

Тема Поиск в словаре

Студент Прохорова Л. А.

Группа ИУ7-53Б

Оценка (баллы) _____

Преподаватели Волкова Л.Л., Строганов Ю.В.

Москва — 2020 г.

Содержание

Введение	2
1 Аналитическая часть	4
Аналитическая часть	4
1.1 Алгоритм поиска в словаре с использованием полного перебора	4
1.2 Алгоритм поиска в словре с использованием бинарного поиска	5
1.3 Комбинированный алгоритм	5
2 Конструкторская часть	7
Конструкторская часть	7
2.1 Описание структуры программного комплекса	7
2.2 Схемы алгоритмов.	8
3 Технологический раздел	14
3.1 Выбор языка программирования	14
3.2 Технические характеристики	14
3.3 Описание данных	14
3.4 Листинги кода	14
3.5 Функциональные тесты	16
4 Исследовательская часть	18
Исследовательская часть	18
4.1 Демонстрация работы программы	18
4.2 Сравнение времени работы	18
Литература	26

Введение

Обычные списки (массивы) представляют собой набор пронумерованных элементов, то есть для обращения к какому-либо элементу списка необходимо указать его номер. Номер элемента в списке однозначно идентифицирует сам элемент. Но идентифицировать данные по числовым номерам не всегда оказывается удобно. Например, маршруты поездов в России идентифицируются численно-буквенным кодом (число и одна цифра), также численно-буквенным кодом идентифицируются авиарейсы, то есть для хранения информации о рейсах поездов или самолетов в качестве идентификатора удобно было бы использовать не число, а текстовую строку.

Структура данных, позволяющая идентифицировать ее элементы не по числовому индексу, а по произвольному, называется словарем или ассоциативным массивом. Каждый элемент словаря состоит из двух объектов: ключа и значения. В жизни широко распространены словари, например, привычные бумажные словари (толковые, орфографические, лингвистические). В них ключом является слово-заголовок статьи, а значением — сама статья. Для того, чтобы получить доступ к статье, необходимо указать слово-ключ.

Другой пример словаря, как структуры данных — телефонный справочник. В нем ключом является имя, а значением — номер телефона. И словарь, и телефонный справочник хранятся так, что легко найти элемент словаря по известному ключу (например, если записи хранятся в алфавитном порядке ключей, то легко можно найти известный ключ, например, бинарным поиском), но если ключ неизвестен, а известно лишь значение, то поиск элемента с данным значением может потребовать последовательного просмотра всех элементов словаря.

Особенностью ассоциативного массива является его динамичность: в него можно добавлять новые элементы с произвольными ключами и уда-

лять уже существующие элементы. При этом размер используемой памяти пропорционален размеру ассоциативного массива. Доступ к элементам ассоциативного массива выполняется хоть и медленнее, чем к обычным массивам, но в целом довольно быстро. = Словари нужно использовать в следующих случаях:

1. Подсчет числа каких-то объектов. В этом случае нужно завести словарь, в котором ключами являются объекты, а значениями — их количество.
2. Хранение каких-либо данных, связанных с объектом. Ключи — объекты, значения — связанные с ними данные.
3. Установка соответствия между объектами (например, “родитель—потомок”). Ключ — объект, значение — соответствующий ему объект.
4. Если нужен обычный массив, но при этом максимальное значение индекса элемента очень велико, но при этом будут использоваться не все возможные индексы (так называемый “разреженный массив”), то можно использовать ассоциативный массив для экономии памяти [1].

1 Аналитическая часть

В данном разделе будет поставлена цель и описаны задачи, описаны алгоритмы которые будут использоваться в лабораторной работе.

Цель данной лабораторной работы: изучить и реализовать алгоритмы поиска по словарю.

Для достижения поставленной цели требуется выполнить следующие задачи.

1. Реализовать алгоритм поиска по словарю с использованием полного перебора, двоичного поиска, комбинированного алгоритма.
2. Изучить алгоритм частотного анализа в задаче поиска по словарю;
3. Провести тестирование работы алгоритмов в худшем, лучшем и произвольном случаях.
4. Провести замеры процессорного времени работы алгоритмов поиска по словарю для каждого ключа и для отсутствующего ключа, вывести минимальное, максимальное и среднее время поиска ключа.
5. Сделать выводы на основе произведённого исследования и описать в отчёте.

1.1 Алгоритм поиска в словаре с использованием полного перебора

Все элементы словаря пересматриваются последовательно в порядке их размещения, пока не найдётся элемент, равный ключу поиска. Если не известно, есть ли искомый элемент, то необходимо следить, чтобы поиск не вышел за границы списка. В таком случае техническим способом повышения эффективности программирования является введение стопера [2].

1.2 Алгоритм поиска в словаре с использованием бинарного поиска

Бинарный поиск производится в упорядоченном словаре.

При бинарном поиске искомый ключ сравнивается с ключом среднего элемента в словаре. Если они равны, то поиск успешен. В противном случае поиск осуществляется аналогично в левой или правой частях словаря.

Алгоритм может быть определен в рекурсивной и нерекурсивной формах.

Бинарный поиск также называют поиском методом деления отрезка пополам или дихотомии.

На каждом шаге осуществляется поиск середины отрезка по формуле $mid = (left + right)/2$.

Если искомый элемент равен элементу с индексом mid , поиск завершается. В случае если искомый элемент меньше элемента с индексом mid , на место mid перемещается правая граница рассматриваемого отрезка, в противном случае — левая граница.

1.3 Комбинированный алгоритм

Перед началом работы алгоритма поиска для словаря, полученного на вход, нужно произвести сегментацию по первой букве, затем выполнить частотный анализ. Для этого нужно для первой буквы каждого значения в словаре посчитать, сколько раз она встречается в качестве первой буквы у других значений. По полученным значениям словарь разбивается на сегменты так, что все элементы с одинаковой первой буквой оказались в одном сегменте. Сегменты сортируются по частоте первых букв. Далее каждый сегмент сортируется в лексикографическом порядке, чтобы можно было применить бинарный поиск в сегменте. Таким образом, сначала для искомого слова выбирается нужный сегмент, а затем в нем выполняется

бинарный поиск [4].

Вывод

В данном разделе поставлена цель и описаны задачи, описаны алгоритмы которые будут использоваться в лабораторной работе.

2 Конструкторская часть

В данном разделе будет представлено описание структуры программного комплекса и схемы алгоритмов.

2.1 Описание структуры программного комплекса

Требования к программе

1. В словаре должно быть более 1000 вхождений.
2. Словарь является уникальным в пределах потока.

Допущения

1. Ключ не является пустой строкой.
2. В функцию бинарного поиска передаётся словарь отсортированный в лексикографическом порядке.
3. В функцию комбинированного алгоритма передаётся словарь разбитый на сегменты отсортированные в порядке частоты, каждый сегмент отсортирован в лексикографическом порядке.

2.2 Схемы алгоритмов.

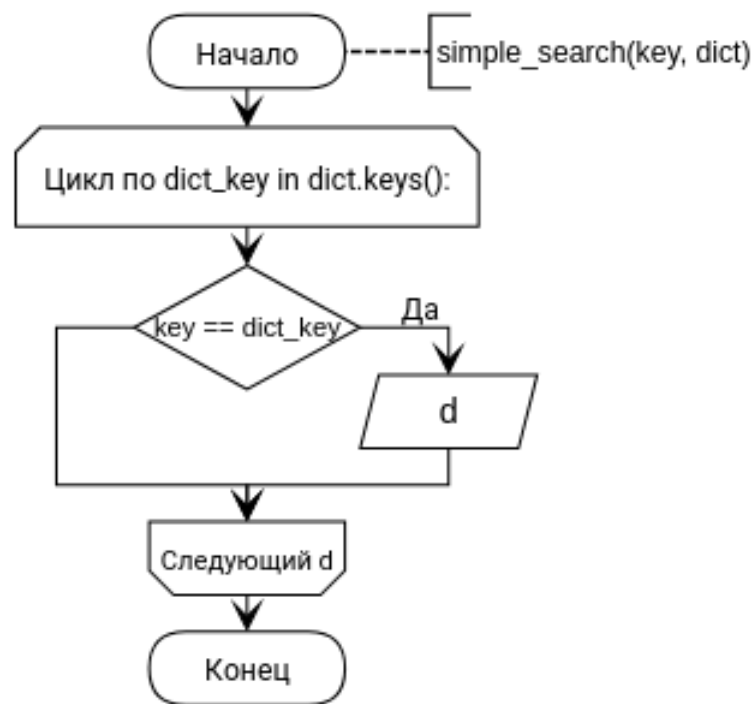


Рисунок 1 – Алгоритм полного перебора.




Рисунок 2 – Алгоритм бинарного поиска.

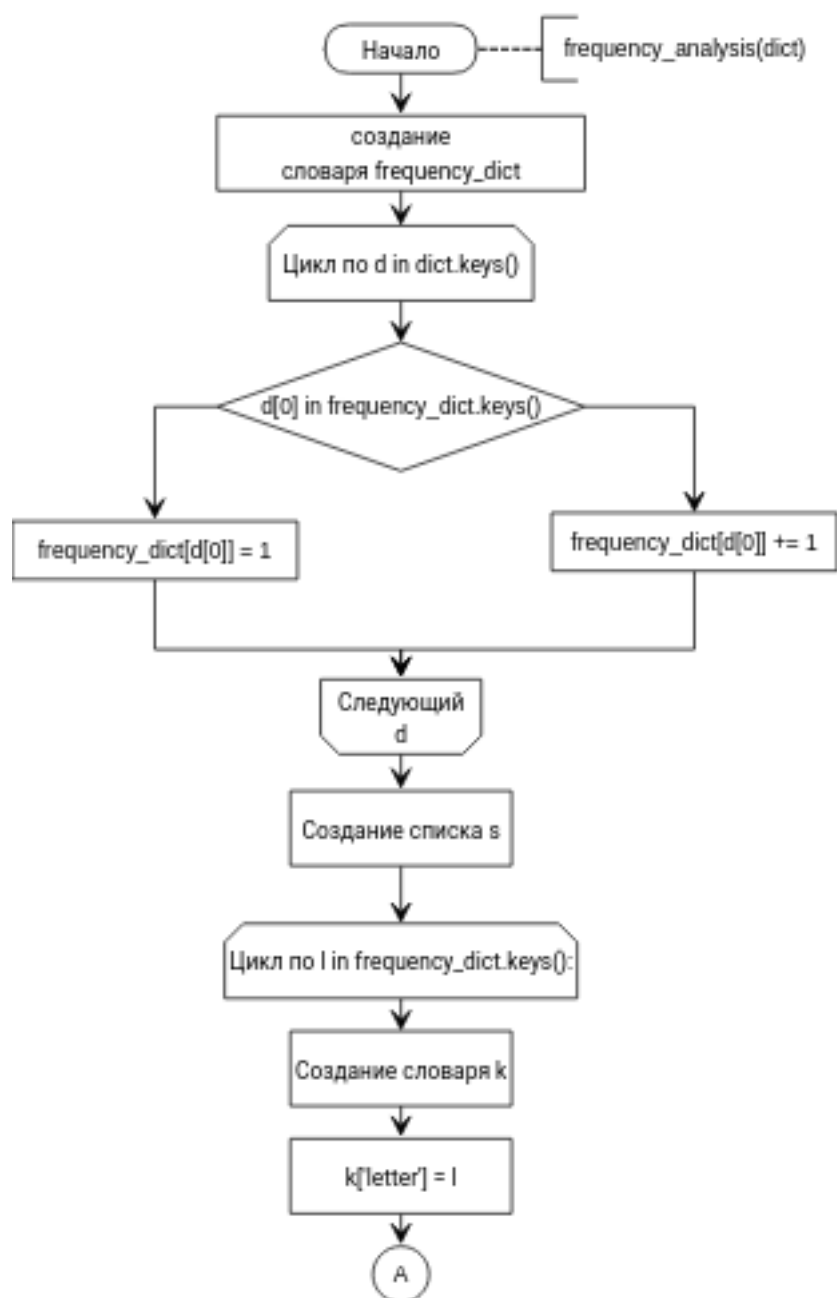


Рисунок 3 – Алгоритм частотного анализа часть 1.



Рисунок 4 – Алгоритм частотного анализа часть 2.

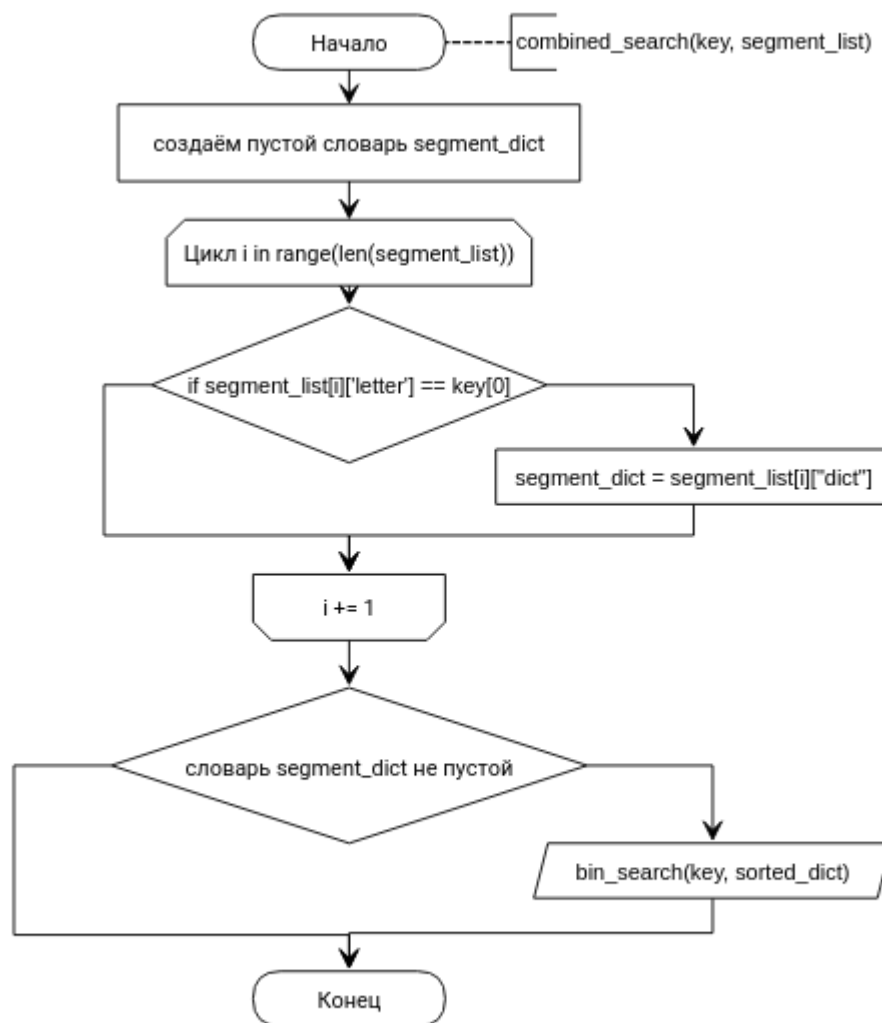


Рисунок 5 – Комбинированный алгоритм.

На рисунке 1 представлен алгоритм полного перебора ключей.

На рисунке 2 представлен алгоритм бинарного поиска. На вход этот алгоритм получает отсортированный в лексикографическом порядке словарь.

На рисунках 3 и 4 представлен алгоритм частотного анализа. В результате работы алгоритма словарь разбивается на сегменты и записывается в список словарей. Каждый словарь в списке содержит поле с идентификатором сегмента (первый символ ключа), количеством слов в этом сегменте и поле словарь которое содержит элементы этого сегмента, отсор-

тированные в лексикографическом порядке.

На рисунке 5 представлен комбинированный алгоритм который получает на вход результат работы частного анализа, выбирает подходящий сегмент и ищет в нём ключ бинарным поиском. Если подходящий сегмент не был найден, то ключа точно нет в словаре и поиск на этом можно прекратить.

Вывод

В данном разделе представлено описание структуры программного комплекса и схемы алгоритмов.

3 Технологический раздел

В этом разделе будет обоснован выбор языка программирования, описаны технические характеристики, приведены листинги кода реализованных алгоритмов.

3.1 Выбор языка программирования

В качестве языка программирования мной был выбран Python так как этот язык удобен для работы с .csv файлами и словарями. Для замера времени выполнения использовалась функция *time()* из библиотеки *time*. Функция *time()* возвращает число секунд, прошедших с начала эпохи. Для операционных систем Unix 1 января 1970, 00:00:00 (UTC) — начало эпохи (момент, с которого время пошло). [5].

3.2 Технические характеристики

Технические характеристики устройства, на котором выполнялось тестирование, следующие.

- Операционная система Ubuntu 18.04 64-bit.
- Память 8 GiB.
- Процессор Intel(R) Core(TM) i7-7700HQ CPU @ 2.80GHz.

3.3 Описание данных

Для словаря взят файл из датасета NBA games data сайта kaggle. Словарь состоит из 1751 элемента. Ключ - номер игрока (*player_id*), значение - имя игрока (*player_name*) из файла *players.csv* [6].

3.4 Листинги кода

Листинг 1 – Алгоритм полного перебора.

```
0 def search_simple(key, dict):
1     for dict_key in dict.keys():
2         if key == dict_key:
3             return dict[key]
4     return None
```

Листинг 2 – Алгоритм бинарного поиска.

```
0 def bin_search(key, sorted_dict):
1     sorted_keys = list(sorted_dict.keys())
2
3     i = 0
4     j = len(sorted_dict) - 1
5     m = int(j / 2)
6
7     while sorted_keys[m] != key and i < j:
8         if key > sorted_keys[m]:
9             i = m + 1
10        else:
11            j = m - 1
12            m = int((i + j) / 2)
13    if i > j:
14        return None
15    else:
16        return sorted_dict[sorted_keys[m]]
```

Листинг 3 – Частотный анализ.

```
0 def frequency_analysis(dict):
1     frequency_dict = {}
2     for d in dict.keys():
3         if d[0] in frequency_dict.keys():
4             frequency_dict[d[0]] += 1
5         else:
6             frequency_dict[d[0]] = 1
7
8     s = []
9     for l in frequency_dict.keys():
10        k = {}
11        k['letter'] = l
```



```

12     k['count'] = frequency_dict[l]
13     k['dict'] = {}
14     for d in dict.keys():
15         if d[0] == l:
16             k['dict'][d] = dict[d]
17
18     sorted_list = sorted(k['dict'].items())
19     sorted_dict = {}
20     for i in range(len(sorted_list)):
21         sorted_dict[sorted_list[i][0]] = sorted_list[i][1]
22     k['dict'] = sorted_dict
23
24     s.append(k)
25
26
27     s.sort(key=lambda val: val['count'], reverse=True)
28     return s

```

Листинг 4 – Комбинированный алгоритм.

```

0 def combined_search(key, segment_list):
1
2     segment_dict = {}
3     for i in range(len(segment_list)):
4         if segment_list[i]['letter'] == key[0]:
5             segment_dict = segment_list[i]["dict"]
6
7     if len(segment_dict) == 0:
8         return None
9
10    return bin_search(key, sorted_dict)

```

3.5 Функциональные тесты

В таблице 1 представлено тестирование программы. Тест 1 - ключ отсутствует в словаре. Тест 2 - ключ является первым элементом словаря. Тест 3 - ключ является последним элементом словаря. Тест 4 - ключ является произвольным элементом словаря.

Таблица 1 – Функциональные тесты

Ключ	Перебор	Бинарный поиск	Комбинированный
'1'	not found!	not found!	not found!
'202711'	'Bojan Bogdanovic'	'Bojan Bogdanovic'	'Bojan Bogdanovic'
'1628778'	'Wesley Maews'	'Wesley Maews'	'Wesley Maews'
'204014'	'Damjan Rudez'	'Damjan Rudez'	'Damjan Rudez'

Фактические результаты тестов совпали с ожидаемыми результатами.

Вывод

В этом разделе обоснован выбор языка программирования, описаны технические характеристики, приведены листинги кода реализованных алгоритмов. Программа прошла тестирование и работает правильно.

4 Исследовательская часть

В этом разделе будет приведена демонстрация работы программы и исследование полученных результатов.

4.1 Демонстрация работы программы

Демонстрация работы программы приведена на рисунках 6, 7. На вход подаётся ключ для поиска в словаре.

```
Введите ключ: 203966
Результат работы алгоритма полного перебора:
Jamil Wilson
Результат работы алгоритма бинарного поиска:
Jamil Wilson
Результат работы комбинированного алгоритма:
Jamil Wilson
```

Рисунок 6 – Демонстрация работы программы (введённый ключ существует).

```
Введите ключ: 0
Результат работы алгоритма полного перебора:
Ключ не найден
Результат работы алгоритма бинарного поиска:
Ключ не найден
Результат работы комбинированного алгоритма:
Ключ не найден
```

Рисунок 7 – Демонстрация работы программы (введённый ключ не существует).

4.2 Сравнение времени работы

На рисунке 8 представлено сравнение времени работы алгоритмов поиска по словарю перебором, бинарным поиском и комбинированным ал-

горитмом в лучшем, худшем,случайном случаях и при отсутствии ключа. Для каждого алгоритма представлено максимальное, минимальное и среднее время выполнения. Для замера времени каждая операция выполнялась 100 раз, среднее время выполнения взято как результат.

Лексикографическая сортировка 0.00108 секунд
Частотный анализ и лексикографическая сортировка 0.001972 секунд

Лучший случай поиска ключа

Алгоритм полного перебора 2.7179718017578123e-07 секунд
Алгоритм бинарного поиска 1.287221908569336e-05 секунд
Комбинированный алгоритм 2.3519992828369142e-05 секунд

Худший случай поиска ключа

Алгоритм полного перебора 7.373571395874023e-05 секунд
Алгоритм бинарного поиска 4.8003196716308595e-05 секунд
Комбинированный алгоритм 2.673149108886719e-05 секунд

Поиск несуществующего ключа

Алгоритм полного перебора 4.336118698120117e-05 секунд
Алгоритм бинарного поиска 1.6965866088867187e-05 секунд
Комбинированный алгоритм 9.34600830078125e-07 секунд

Поиск случайного ключа

Алгоритм полного перебора 2.8128623962402345e-05 секунд
Алгоритм бинарного поиска 1.8036365509033204e-05 секунд
Комбинированный алгоритм 1.640796661376953e-05 секунд

Алгоритм перебором

Максимальное время выполнения = 0.0001481151580810547
Минимальное время выполнения = 2.8133392333984374e-07
Среднее время выполнения = 3.207051229776482e-05

Бинарный поиск

Максимальное время выполнения = 6.932735443115234e-05
Минимальное время выполнения = 1.0755062103271484e-05
Среднее время выполнения = 1.9452014968845912e-05

Комбинированный алгоритм

Максимальное время выполнения = 7.044792175292969e-05
Минимальное время выполнения = 1.2617111206054688e-05
Среднее время выполнения = 2.0590693115983815e-05

Рисунок 8 – Время работы алгоритмов в разных случаях

Для алгоритма поиска перебором лучший случай - это поиск слов, которые находятся первыми в словаре, худший случай - поиск последних слов словаря.

Для алгоритма с бинарным поиском лучший случай - это поиск слова, которое находится в середине отсортированного в лексиграфическом порядке словаря, худший случай - слово находится при последнем делении диапазона поиска пополам.

Для комбинированного алгоритма лучший случай - это поиск слова, которое начинается на букву, которая чаще всего встречается в качестве первой буквы слова и находится в середине отсортированного в лексиграфическом порядке массива слов, начинающихся с этой же буквы; худший случай - слово, которое начинается на букву, которая реже всего встречается в качестве первой буквы слова и находится при последнем делении диапазона поиска пополам (в этом случае время выбора нужного сегмента будет больше, но время поиска в этом коротком сегменте меньше).

На рисунке 9 представлен график, для построения которого использовались данные о времени поиска каждого элемента в словаре (1751 элемент). Индекс ключа указан на горизонтальной оси.




Рисунок 9 – Время работы алгоритмов для поиска каждого ключа словаря

Для большей наглядности будем использовать для построения графика меньше точек (возьмём данные о времени поиска каждого пятнадцатого элемента словаря). График представлен на рисунке [10](#)

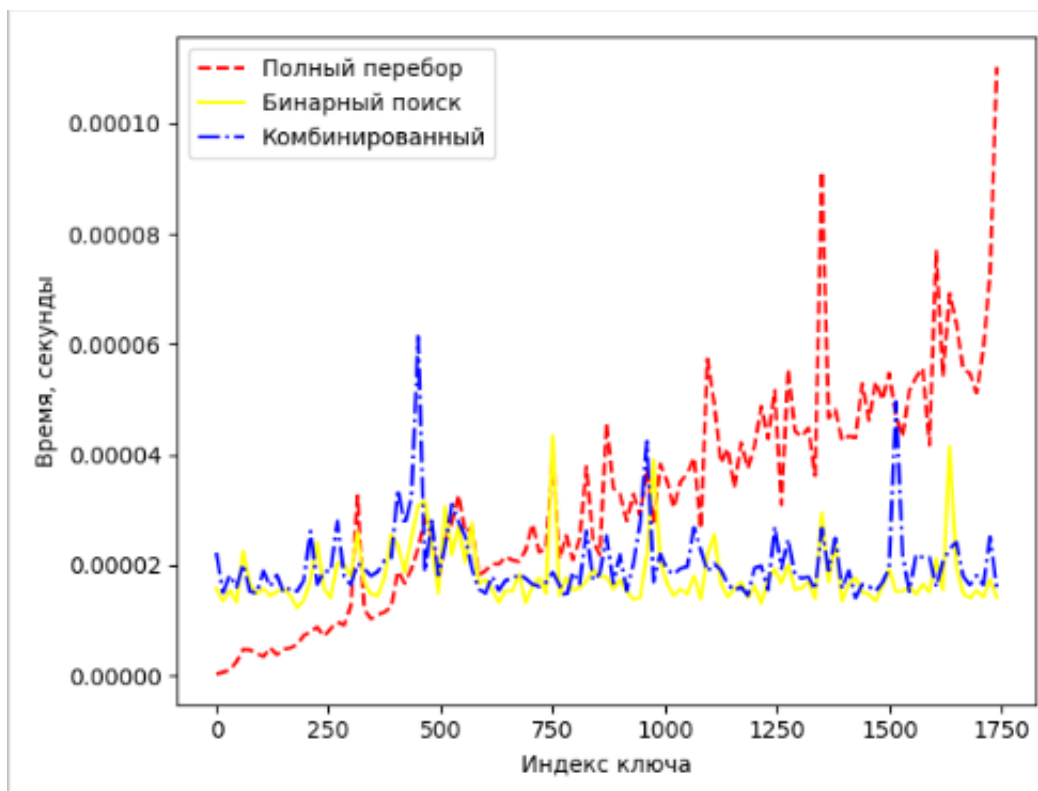


Рисунок 10 – Время работы алгоритмов для поиска каждого пятнадцатого ключа словаря

Вывод

Как видно из графиков на рисунках 9, 10 самый медленный алгоритм - алгоритм полного перебора. Время на в нём растет линейно и увеличивается с увеличением индекса элемента словаря. Алгоритм бинарного поиска и комбинированный алгоритм тратят примерно одинаковое количество времени, при этом они требуют дополнительных расходов времени на подготовку данных к работе с алгоритмом, но эти расходы малы.

Однако в лучшем случае алгоритм перебором показывает самые лучшие результаты. Он работает в 4 раза быстрее алгоритма бинарного поиска и в 8 раз быстрее комбинированного алгоритма.

В худшем случае алгоритм перебором затрачивает в 1.75 раза больше времени чем бинарный поиск и в 3.5 раза больше времени чем комбинированный алгоритм. Комбинированный алгоритм в худшем случае работает

быстрее остальных алгоритмов. При поиске несуществующего ключа комбинированный алгоритм тоже работает быстрее всех.

Заключение

В ходе данной лабораторной работы была достигнута цель: изучены и реализованы алгоритмы поиска по словарю.

Для достижения поставленной цели выполнены следующие задачи.

1. Реализован алгоритм поиска по словарю с использованием полного перебора, двоичного поиска, комбинированного алгоритма.
2. Изучен алгоритм частотного анализа в задаче поиска по словарю;
3. Проведено тестирование работы алгоритмов в худшем, лучшем и произвольном случаях.
4. Проведены замеры процессорного времени работы алгоритмов поиска по словарю для каждого ключа и для отсутствующего ключа, вывести минимальное, максимальное и среднее время поиска ключа.
5. Сделаны выводы на основе произведённого исследования.

Алгоритм полного перебора работает хорошо в лучшем случае (когда искомые ключи находятся в самом начале словаря). Однако для работы лучше использовать алгоритм бинарного поиска или комбинированный алгоритм. Они работают примерно одинаково по времени, но комбинированный алгоритм выигрывает в случае несуществующего ключа или худшем случае. В среднем алгоритм полного перебора работает в два раза дольше чем остальные алгоритмы.

Список литературы

- [1] Словари (ассоциативные массивы) в Python [Электронный ресурс]. - Режим доступа: <https://foxford.ru/wiki/informatika/slovari-assotsiativnye-massivy-v-python> Дата обращения 30.11.2020.
- [2] Алгоритмы последовательного поиска [Электронный ресурс]. - Режим доступа: <https://cyberpedia.su/9x4e62.html> Дата обращения 30.11.2020
- [3] Бинарный поиск [Электронный ресурс]. Режим доступа: <https://prog-cpp.ru/search-binary/> Дата обращения 30.11.2020
- [4] Алгоритмы программирования [Электронный ресурс]. - Режим доступа: <https://otus.ru/nest/post/829/> Дата обращения 30.11.2020
- [5] Модуль time в Python [Электронный ресурс]. - Режим доступа: <https://pythonru.com/osnovy/modul-time-v-python> Дата обращения 01.12.2020
- [6] NBA games data [Электронный ресурс]. - Режим доступа: <https://www.kaggle.com/nathanlauga/nba-games> Дата обращения 01.12.2020